

RESUMEN

Se realizó una revisión sistemática sobre el reconocimiento de imágenes de polinizadores mediante aprendizaje profundo. La búsqueda se efectuó en Scopus, siguiendo el enfoque PRISMA para la identificación, cribado e inclusión de estudios. El corpus final estuvo conformado por 53 investigaciones publicadas desde 2020, centradas en clasificación, detección y segmentación. Para ordenar la heterogeneidad de la literatura, los estudios se analizaron mediante bloques metodológicamente semejantes según tarea, arquitectura y métricas reportadas. Los resultados muestran un predominio de la detección y de la familia YOLO, junto con modelos como ResNet, MobileNet, EfficientNet, Faster R-CNN y Mask R-CNN. Las métricas más frecuentes fueron exactitud, precisión y sensibilidad; en detección destacaron mAP, IoU y FPS. Además, el rendimiento se asoció con estrategias como aumento de datos, aprendizaje por transferencia y métodos de optimización.

Palabras clave: Aprendizaje profundo, Métricas de desempeño, Polinizadores, Reconocimiento de imágenes, Visión por computador.

DESARROLLO

1. Introducción

Los polinizadores son esenciales para la biodiversidad, la estabilidad de los ecosistemas y la seguridad alimentaria; su declive exige sistemas de monitoreo más eficaces y reproducibles (Ghosh & Hasan, 2025; Hellwig et al., 2024). La visión por computador y el aprendizaje profundo permiten automatizar su identificación, aunque esta sigue siendo compleja por la similitud morfológica, la variabilidad visual y los fondos naturales (Calisan & Olgun, 2025; Høye et al., 2021; Spiesman et al., 2021). Por ello, se requiere sintetizar la literatura reciente sobre modelos, métricas y protocolos de evaluación (Nizam et al., 2020).

2. Objetivo general


Caracterizar el estado del arte en el reconocimiento de imágenes de polinizadores en aprendizaje profundo, mediante una revisión sistemática de estudios científicos desde 2020 sobre redes neuronales en clasificación, detección o segmentación.

3. Preguntas de investigación

RQ1. ¿Qué arquitecturas y tipos de modelos se utilizan con mayor frecuencia?
RQ2. ¿Qué métricas de evaluación se reportan con mayor recurrencia?
RQ3. ¿Qué factores técnicos se asocian con mejores niveles de desempeño?


4. Metodología

Revisión sistemática cualitativo-descriptiva guiada por PRISMA.



5. RQ1: Tareas y arquitecturas


La detección fue la tarea predominante, seguida por la clasificación y la segmentación. Este patrón explica la alta presencia de modelos orientados a localización de objetos, especialmente YOLO, por su eficiencia en escenarios de monitoreo visual automatizado.



Nota. Elaboración propia.

6. RQ2: Métricas

Las métricas varían según la tarea: clasificación prioriza exactitud, precisión, sensibilidad y F1; detección emplea mAP, IoU y FPS; y segmentación utiliza IoU, Dice y F1.



Nota. Elaboración propia.

7. RQ3: Factores técnicos

El aumento de datos fue la estrategia más reportada, seguida por transferencia de aprendizaje y optimización, debido a la limitada disponibilidad de datos, el desbalance de clases y la variabilidad visual de los polinizadores.



Nota. Elaboración propia.

8. Bloques de comparación

Tarea	Modelos frecuentes	Métricas clave	Factores técnicos
Clasificación	CNN, ResNet, EfficientNet, Inception y MobileNet	Exactitud, precisión, sensibilidad y F1	Transferencia de aprendizaje, aumento de datos y optimización
Detección espacial	YOLO, Faster R-CNN y Mask R-CNN	mAP, IoU y FPS	Ajuste fino, aumento de datos y tasa de aprendizaje
Detección general	YOLO, Faster R-CNN, Mask R-CNN y ResNet	Exactitud, precisión, sensibilidad y F1	Transferencia de aprendizaje, aumento de datos y optimización
Segmentación	Mask R-CNN, YOLO y otros enfoques	IoU, Dice y F1	Aumento de datos, transferencia de aprendizaje y ajuste fino

Nota. Elaboración propia.

CONCLUSIONES

- El reconocimiento de imágenes de polinizadores mediante aprendizaje profundo debe analizarse según la tarea que se busca resolver. La detección permite localizar organismos en escenarios de monitoreo automatizado, la clasificación aporta a la diferenciación taxonómica y la segmentación permite una delimitación espacial más precisa del polinizador frente al fondo.
- La pertinencia de una arquitectura depende de su correspondencia con el objetivo técnico del estudio. Modelos como YOLO resultan adecuados cuando se requiere localización eficiente, mientras que ResNet, EfficientNet, MobileNet e Inception son más útiles cuando el interés principal es clasificar especies, familias o grupos funcionales.
- La comparación del desempeño requiere interpretar qué mide cada métrica dentro de la tarea evaluada. En clasificación, las métricas valoran la asignación correcta de categorías; en detección, integran localización y eficiencia; y en segmentación, permiten medir la coincidencia espacial entre el polinizador y la predicción del modelo.
- El rendimiento depende del modelo y de los factores técnicos aplicados en el entrenamiento. El aumento de datos aporta robustez frente a cambios de escala, postura e iluminación; el aprendizaje por transferencia facilita adaptar representaciones visuales previas al dominio de polinizadores; y la optimización contribuye a una convergencia más estable del modelo. La comparación por bloques metodológicos permite interpretar estos factores dentro de estudios con tareas, métricas y condiciones de evaluación semejantes.

REFERENCIAS

Alex, A. J., Barnes, C. M., Machado, P., Ihanlie, I., Markó, G., Bencsik, M., & Bird, J. J. (2025).Enhancing pollinator conservation: Monitoring of bees through object recognition. *Computers and Electronics in Agriculture*, 228, 109665. <https://doi.org/10.1016/j.compag.2024.109665>

Bjerger, K., Mann, H. M. R., & Høye, T. T. (2022).Real-time insect tracking and monitoring with computer vision and deep learning. *Remote Sensing in Ecology and Conservation*, 8(3), 315-327. <https://doi.org/10.1002/rse2.245>

Calisan, M., & Olgun, N. (2025).Evaluation of Classification Performance of Honey Bee Species With Deep Learning Models. *Electrica*, 25. <https://doi.org/10.5152/electrica.2025.24157>

Ghosh, S., & Hasan, M. N. (2025). Plant-pollinator interaction. *En Pollinators: Life, Biology and Threats* (pp. 63-73). Springer. https://doi.org/10.1007/978-981-95-0359-9_4

Hellwig, N., Sommerlandt, F. M. J., Graben, S., Lindemann, L., Sickel, W., Krüger, L., & Dieker, P. (2024).Six steps towards a spatial design for large-scale pollinator surveillance monitoring. *Insects*, 15(4), 229. <https://doi.org/10.3390/insects15040229>

Høye, T. T., Arje, J., Bjerger, K., Hansen, O. L. P., Iosifidis, A., Leese, F., Mann, H. M. R., Meissner, K., Melvad, C., & Raitoharju, J. (2021).Deep learning and computer vision will transform entomology. *Proceedings of the National Academy of Sciences*, 118(2), e2002545117. <https://doi.org/10.1073/pnas.2002545117>

Nizam, A., Mohd-Isa, W. N., & Ali, A. B. (2020).Image segmentation of meliponine bee using Mask-RCNN. *International Journal of Engineering Trends and Technology*, 17-21. <https://doi.org/10.14445/22315381/CATI2P203>

Spiesman, B. J., Gratton, C., Hatfield, R. G., Hsu, W. H., Jepsen, S., McCormack, B., Patel, K., & Wang, G. (2021).Assessing the potential for deep learning and computer vision to identify bumble bee species from images. *Scientific Reports*, 11, 7580. <https://doi.org/10.1038/s41598-021-87210-1>

Stark, T., Ștefan, V., Wurm, M., Spanier, R., Taubenböck, H., & Knight, T. M. (2023).YOLO object detection models can locate and classify broad groups of flower-visiting arthropods in images. *Scientific Reports*, 13, 16364. <https://doi.org/10.1038/s41598-023-43482-3>